

UN ALGORITMO DI OTTIMIZZAZIONE IN VEDERLO PRESENTA UNO SCHEMA CONTROLE.

A PARTIRE DA UN PUNTO $x^0 \in \mathbb{M}^n$ SI FA UN CALCOLO FINO A QUANDO $Df(x^n) \neq 0$ ANDANDO AD AGGIORNARE DANS VOUS IL VALORE DI x^n .

L'ALGORITMO:

```
SE  $x^0 \in \mathbb{M}^n$  E  $K \in \mathbb{C}$ 
WHILE ( $Df(x^K) \neq 0$ )
    - CALCOLA LO SPOSTAMENTO  $S_K$ 
     $x^{K+1} = x^K + S_K$ 
END
RETURN  $x$ 
```

QUESTO ALGORITMO PRODUCE UNA SEQUENZA DI SOLUZIONI

$\{x^n\} \subset \mathbb{M}^n$ A CUI SONO ASSOCIATE LE SEGUENTI:

- $\{f(x^n)\} \subset \mathbb{R}^m \rightarrow$ SEQUENZA DELLE IMMAGINI

$\{\nabla f(x^n)\} \subset \mathbb{R}^m \rightarrow$ SEQUENZA DELLE GRADIENTI

- $\nabla f(x) = 0$ seguono da gradiente

5. POSSONO PIÙ AVERE DUE SITUAZIONI DIVERSE:

. $\exists \bar{x} \text{ t.c. } \nabla f(\bar{x}) = 0$ (convessità funz)

. $\{x^n\}$ ha seguenti infiniti



PIREMMO PIÙ CHE LA SITUAZIONE CONVERGENTE VERSO UN OTTIMO DEL PROBLEMA, MENO SI RICHTOG.

① ESISTENZA DEI PUNTI DI ACCUMULAZIONE PER $\{x^n\}$, MENO

$\exists u_1, u_2, \dots$ TAU CHE: $\lim_{j \rightarrow \infty} x^{u_j} = \bar{x}$

MENO CHE $\{x^n\}$ AMMETTA UNA SOTTOSEQUENZA CONVERGENTE

② CHE $\{x^n\}$ SIA CONVERGENTE ASINTOTICAMENTE VERSO UN STAZIONARIO

③ CHE $\{x^n\}$ CONVERGA RAPIDAMENTE

④ ESISTENZA DEI PUNTI DI ACCUMULAZIONE

SIA f CONTINUA E SIA $x^* \in \mathbb{R}^m$ TAU CHE L'insieme DI LEVELLO

$$S_0 = \left\{ x_0 \in \mathbb{R}^n \mid f(x) \leq f(x^*) \right\}$$

SIA **COMPATTO**. SUPPOSSIMO DI GENERARE UNA SEQUENZA $\{x^n\}$
DEL TIPO:

$$x^{n+1} = x^n + s_n$$

→ LA FUNZIONE DECRESCE AD OGNI PASSO

PER CHE:

$$f(x^{n+1}) \leq f(x^n)$$

ALCUNI:

1) $\{x^n\}$ HA PUNTI DI ACCUMULAZIONE E GLI PUNTI DI ACCUMULAZIONE
APPARTENGONO ALL'INSIEME DI LEVELLO

2) LA SEQUENZA $\{f(x^n)\}$ CONVERGE A UN VALORE FINITO.

DIM:

1) PER LE IPOTESI SI HA CHE $f(x^{n+1}) \leq f(x^n)$. PER INDUZIONE
SI HA CHE $f(x^{n+1}) \leq f(x^*)$ SUPPOSSANDO CHE $f(x^n) \leq f(x^*)$.

PERCHÉ $x^{n+1} \in S_0$ PER LA DEFINIZIONE DI S_0 , E' QUINDI

$\{x^n\} \subseteq S_0$ DOVE S_0 È COMPATTO PER IPOTESI. ALLORA $\{x^n\}$

HA PUNTI DI ACCUMULAZIONE, OLTRE AI QUANTI APPARTENGONO ALL'

INSIEME DI LIVELLI 2. PER DEFINIZIONE!

□

2)

ESSENDO $f(x^{n+1}) \leq f(x^n)$ ALLORA $\{f(x^n)\}$ È MONOTONICA
CRESCENTE, PUNTO ESISTE IL LIMITE.

$$\boxed{\lim_{n \rightarrow \infty} f(x^n) = \bar{f}}$$

POSSIAMO INOLTRE CONSIDERARE UNA SOTTOSPETTACOLARE $K \subseteq \{0, 1, \dots\}$
 TALE CHE:

$$\boxed{\lim_{n \rightarrow \infty} x^n = \bar{x} \quad \forall n \in K}$$

Dove K ESISTE PER IL PUNTO ①. VIRE ALLORA CHE, PER
 LA CONTINUITÀ DI f :

$$\boxed{\lim_{\substack{n \rightarrow \infty \\ n \in K}} f(x^n) = f(\bar{x}) = \bar{f}}$$

□

2)

CONVERGENZA VERSO UN SISTOZIONARIO

SI HANNO 3 DIVERSI CASI DI CONVERGENZA:

$$\boxed{\lim_{n \rightarrow \infty} x^n = \bar{x}}$$



→ CONDIZIONE NECESSARIA: SI HA PLENA CONVERGENZA VERSO

$n \rightarrow \infty$

UN PUNTO STAZIONARIO

$$\lim_{n \rightarrow \infty} \|\nabla f(x^n)\| = 0 \quad \rightarrow \text{IL GRADIENTE TENDE A ZERO, DENTRO TUTTI I PUNTI DI ACCUMULAZIONE SONO STAZIONARI}$$

$$\lim_{n \rightarrow \infty} \|\nabla f(x^n)\| = 0 \quad \rightarrow \text{ALMENO UN PUNTO DI ACCUMULAZIONE È STAZIONARIO}$$

(→ Condizione PIÙ DEBOLE MA LI MINIMA RICHIESTA!)

Indica IL VALORE MINIMO
A CUI RIBASSA I VALORI DEL GRADIENTE
CALCOLATI PER OGNI PUNTO x^n

ESEMPIO:

(→ NELLA SUA VERSO DELLA SUCCESSONE TENDE AD UN PUNTO STAZIONARIO)

SCEGLI $f(x) = (x-1)(x-3)$, DEFINIAMO:

$$x^n = \left\{ 0,9; 0,99; 0,999; 0,9999, \dots \right\} \quad \rightarrow \text{IN QUESTO CASO SI HA CHE TUTTA LA SEQUENZA CONVERGE AL 1, DENTRO UN PUNTO STAZIONARIO} \rightarrow \text{CASO ①}$$

$$x^n = \left\{ 0,9; 2,9; 0,99; 2,99, \dots \right\} \quad \rightarrow \text{IN QUESTO CASO UNA SOTTOSEQUENZA CONVERGE AL 1 E L'ALTRA A 3} \Rightarrow \nabla f(x^n) \rightarrow 0 \rightarrow \text{CASO ②}$$

$$x^n = \left\{ 1; 6; 1; 6; 1; 6, \dots \right\} \quad \rightarrow \text{SI HANNO DUE SOTTOSEQUENZE CONVERGENTI DOVE SOLAMENTE UNA CONVERGE AD UN PUNTO DI ACCUMULAZIONE} \rightarrow \text{CASO ③}$$

③ VELOCITÀ DI CONVERGENZA:

Si dice che una sequenza $\{x^n\}$ convergente ad x^* ha
TASSO DI CONVERGENZA:

- SUBLINERAGE**: $\lim_{n \rightarrow \infty} \frac{\|x^{n+1} - x^*\|}{\|x^n - x^*\|} = 1 \rightarrow$ PIÙ SI PROGREDE CON L'ITERAZIONE E MENO PROGRESSO SI FA, ANDRA SÌ PENSIS SEMPRE PIÙ A RALLENTARE
- LINERAGE**: $\lim_{n \rightarrow \infty} \frac{\|x^{n+1} - x^*\|}{\|x^n - x^*\|} = c \in (0, 1) \rightarrow$ AD OGNI PASSO DELL'ITERAZIONE CI SI AVVICINA ALLA SOLUZIONE CON RATE COSTANTE
- SUPERLINERAGE**: $\lim_{n \rightarrow \infty} \frac{\|x^{n+1} - x^*\|}{\|x^n - x^*\|} = 0 \rightarrow$ SI VA SEMPRE PIÙ VELOCemente A CIASCUA ITERAZIONE, È L'OPPOSTO DELLA SUBLINERAGE
- QUADRATICO**: $\lim_{n \rightarrow \infty} \frac{\|x^{n+1} - x^*\|}{\|x^n - x^*\|^2} = c < 1 \rightarrow$ È IL CASO A VELOCITÀ MAGGIORA!

CLASSIFICAZIONE DI ALGORITMI
DI OTIMIZZAZIONE

(A PRIMA SUDDIVISIONE SI BOSCA SULLE INFORMAZIONI RECESEVTE ALLE DISPONIBILITÀ D) $f, \nabla f, \nabla^2 f$

- ALGORITMI DI PRIMO ORDINE**: SI CALCOLA $f(x), \nabla f(x)$
- ALGORITMI DI SECONDO ORDINE**: SI CALCOLA $f(x), \nabla f(x), \nabla^2 f(x)$
- ALGORITMI DI ORDINE ZERO**: SI CALCOLA $f(x)$

GLI ALGORITMI CONVERGENTI SI DIVIDONO IN:

- GEOBRANTE CONVERGENT: SE $\{x^k\}$ SI HO CHE
 $\{x^n\}$ CONVERGE A \bar{x} CON $\nabla f(\bar{x}) = 0$
- LOCIMENTE CONVERGENT: SE $\{x^n\}$ CONVERGE A \bar{x}
 CON $\nabla f(\bar{x}) = 0$ NEL INTORO $B_p(\bar{x})$

INFINE SI DISTINGUE 3 TIPOLOGIE DI ALGORITMI:

- ① TIPO UNISERCAH
- ② TIPO TRUST-REGION
- ③ TIPO DIRECT-SEARCH

ALGORITMO UNI-SEARCH

DATI $x^0 \in \mathbb{R}^n$ E $f(x)$ IL GENERICO ALGORITMO È:

WHILE ($\nabla f(x^n) \neq 0$):

- SI SCHEDE CON DIREZIONE d_n
- SI ACCADE UN PASSO $\alpha_n > 0$

• Si pone $\underline{X}''' = \underline{X}'' + 2u du$

• $u = u+1$

END WHILE

DEFINIZIONE FUNZIONE DI FORZAMENTO

Sia $\delta: \mathbb{R}^+ \rightarrow \mathbb{R}^+$, $\underline{\delta}$ è una FUNZIONE DI FORZAMENTO

se $\forall \{t^n\}$ reale che:

$$\lim_{n \rightarrow \infty} \delta(t^n) = 0$$

allora vale che:



$$\lim_{n \rightarrow \infty} t^n = 0$$

ovvero, se si ha che $\delta(t_n) \rightarrow 0$, allora siam sicuri che anche l'argomento $t_n \rightarrow 0$.

Ad esempio $\delta(t) = ct$ con $c > 0$ è tale che se

$$\lim_{n \rightarrow \infty} \delta(t^n) = \lim_{n \rightarrow \infty} ct^n = 0$$

Allora $t_u \rightarrow \infty$ per $u \rightarrow \infty$

Sia $f \in C^1(\mathbb{R}^n)$ e sia $x^* \in \mathbb{R}^n$ t.c: \mathcal{L}_0 sia compatto.

Sia $\{x^u\}$ una sequenza fissa con $\nabla f(x^u) \neq 0 \forall u$; si

allora le seguenti condizioni:

1 $f(x^{u+1}) \leq f(x^u)$ mostra la crescita

2 $\lim_{k \rightarrow \infty} \frac{\nabla f(x^k)^T d_u}{\|d_u\|} = 0$

3 $\frac{\nabla f(x^u)^T d_u}{\|d_u\|} \geq -\sigma / (\|\nabla f(x^u)\|)$ con $\sigma > 0$ fissato

Allora, se tutte tre queste risultano verificate, si ha:

a $\{x^u\} \subseteq \mathcal{L}_f(x^u)$

b $\{x^u\}$ ha tutti i punti di accumulazione appartenenti a \mathcal{L}_0

c $\{f(x^u)\}$ è convergente ad un valore finito f

[d] $\lim_{n \rightarrow \infty} \|\nabla f(x^n)\| = 0$

[e] CIASCU^N PUNTO DI ACCUMULAZIONE DI $\{x^n\}$ È STAZIONARIO

D.i.m:

I PUNTI a, b, c SONO DUE CONTINUI^O DI f , DUE COMPETIZIONI N

\Rightarrow SONO DUE MIGLIORANTI DI $\{f(x^n)\}$

(d) : Dalle ipotesi SAPPIAMO CHE:

$$\frac{|\nabla f(x^n)^T d_n|}{\|d_n\|} \geq \delta (\|\nabla f(x^n)\|) \geq 0$$

SE SI CONSIDERA IL QUOTIENTE PER $n \rightarrow \infty$ SI HA CHE IL MEMBRO DI SINISTRA TENDE A ZERO, ALLORA!

$$\lim_{n \rightarrow \infty} \delta (\|\nabla f(x^n)\|) = 0$$

MA ESSENDO δ DI FERZAMENTO SI HA CHE:

$$\lim_{n \rightarrow \infty} \|\nabla f(x^n)\| = 0 \quad \square$$

c) considero una sottosequenza $K \subseteq \{0, 1, \dots\}$ tale che

$$\boxed{\lim_{n \rightarrow \infty} x^n = \bar{x} \quad n \in K}$$

Allora:

$$0: \lim_{n \rightarrow \infty} \|\nabla f(x^n)\| = \lim_{n \rightarrow \infty} \|\nabla f(x^n)\| \underset{n \in K}{=} \|\nabla f(\bar{x})\|$$

\hookrightarrow UN'ALTRA SOTTOSERIE
 \hookrightarrow UNA SEQUENZA

$$f \circ C(m^n)$$

$$\Rightarrow \|\nabla f(\bar{x})\| = 0 \Rightarrow \text{UN PUNTO DI ACCUMULAZIONE}$$

CONSIDERANDO IL VETTORE UN PUNTO STABILISSIMO

OSSERVAZIONE

POSSIAMO DISCOVRIRE LA CONDIZIONE (2) NEL SEGUENTE MODO:

$$\boxed{\nabla f(x^u)^T \cdot \frac{du}{\|du\|} \rightarrow 0}$$

È TRAMITE LA normalizzazione DELL' DIREZIONE du SULLA NORMA TALE UNITA INDEPENDENTE DAL VALORE DI du

PENSANO DEVE ESSERE LA DERIVATA DIREZIONALE $\nabla f(x^u)^T du$ A RISULTARE A ZERO E NON LA LUNGHEZZA DELL' DIREZIONE du !

INOLTRE, NON DEVE VERIFICARSI CHE, IN MANIERA ASSURDA, du RISULTI PERPENDICOLARE AL GRADIENTE:

SIA $\delta(t) = ct$ con $c > 0$. SUPPOSSO CHE, ALLORA (3):

$$\boxed{\left| \frac{\nabla f(x^u)^T du}{\|du\|} \right| \geq c \|\nabla f(x^u)\|}$$

SE $\nabla f(x^u)^T du < 0$, allora:

$$\boxed{\frac{\nabla f(x^u)^T du}{\|du\| \cdot \|\nabla f(x^u)\|} \leq -c < 0}$$

E POSSIAMO SCRIVERE CHE:

IL COSEGUENZO
PER du E $\nabla f(x^u)$
 $\geq 90^\circ$ (?)

$$\boxed{\frac{\nabla f(x^u)^T du}{\|du\|} = \cos(\theta(du, \nabla f(x^u)))}$$

$$\|d_K\| \cdot \|\nabla f(x^u)\|$$

↳ considerare d'angolo

SE PRENDIAMO, COME DIREZIONE, L'ANTIGRAVITÀ?

SIA $d_u = -\nabla f(x^u)$

$$\Rightarrow \frac{\nabla f(x^u)^T (-\nabla f(x^u))}{\|\nabla f(x^u)\| \cdot \|\nabla f(x^u)\|} = \frac{-\|\nabla f(x^u)\|^2}{\|\nabla f(x^u)\|^2} = -1$$

↳ quindi l'angolo
tra d_u e $\nabla f(x^u)$
è massimo di 90°

⇒ considerare SODDISFAZIONE ✓

SE INVECE SCEGLIAMO $d_u = -H_u \nabla f(x^u)$ CON H_u MATE

D.P. TALE CHE:

- $\lambda_{\min}(H_u) \geq m$
- $\lambda_{\max}(H_u) \leq M$

SI OTTIENE CHE:

$$\nabla f(x^u)^T d_u = -\nabla f(x^u)^T H_u \nabla f(x^u) \leq 0$$

Se $\nabla f(x^u) \neq 0$ OTTIMEZZA;

$$|\nabla f(x^u)^T d_K| = \left\| -\nabla f(x^u)^T H_u \nabla f(x^u) \right\|_{\mathbb{R}^m} \leq M \|\nabla f(x^u)\|^2$$

$$\|d_K\| = \|H_u \nabla f(x^u)\| \leq M \|\nabla f(x^u)\|$$

PUNTO SI AVRA:

$$\frac{|\nabla f(x^u)^T d_K|}{\|d_K\|} \geq \frac{m}{M} \|\nabla f(x^u)\|$$

E PUNTO SEGUENDO $C = \frac{m}{M}$ SI HA CHE IN SEGUENTE PASSO DI GLI VEDI A SODDISFARE LA CONDIZIONE D'ANALOGO.

LINE-SEARCH: SEGUO DEL PASSO α_n

VEDIAMO ADesso COME È POSSIBILE SEGUERE IL PASSO α_n PER SOSTITUIRE UNICO IN DIREZIONE DI DISCESA d_K .

L'OBIETTIVO È QUINDI PUÒSI DI SEGUIRE α_n DI USARE IN

$$x^{n+1} = x^n + \alpha_n d_K$$

CERCHIO DI MINIMIZZARE

$$f(x^k + \alpha_k d_K)$$

SI DISTINGUENO DUE SITUAZIONI:

- RICERCA DI UNA GSATTA:

$$\alpha_k = \underset{\alpha}{\operatorname{argmin}}_2 f(x^k + \alpha d_k)$$

- RICERCA DI UNA INGSATTA:

$$\alpha_k \approx \underset{\alpha}{\operatorname{argmin}}_2 f(x^k + \alpha d_k)$$

RICERCA DI UNA GSATTA

SE CONSIDERAMO

$$f(\alpha) = f(x^k + \alpha d_k)$$

OTTENIAMO:

$$l'(\alpha) = \nabla f(x^k + \alpha d_k)^T d_k$$

$$l(0) = f(x^k)$$

$$l'(\alpha) = \nabla f(x^k)^T d_k$$

VOLUO CHE IN MODO CHE

$$\alpha_k = \underset{\alpha}{\operatorname{argmin}}_2 l(\alpha)$$

OVRUSSE CERCARE α TALE CHE

$$l'(\alpha) = 0$$

In esempio di line-search OSATI si ha nel caso del classico problema quadritico:

$$\min_{x \in \mathbb{R}^n} \frac{1}{2} x^T Q x + c^T x \text{ con } \underbrace{Q}_{\text{D.P.}}$$

INPUCA
1) SIROTTA
CONVESSITÀ!

Supponiamo quindi di essere in un punto x^k e di voler effettuare un certo spostamento verso una direzione d_k :

$$f(x) = f(x^k + \alpha d_k) \stackrel{\substack{\text{calcolano lo} \\ \text{sostanzamento}}}{=} f(x^k) + \alpha \nabla f(x^k)^T d_k + \frac{1}{2} \alpha^2 d_k^T Q d_k$$

APPROXIMAZIONE
SECONDO TAYLOR

SAREBBE $\nabla^2 f(x)$ se sapevamo
che nel caso quadratico $\nabla^2 f(x) = Q$ era

NOTIAMO CHE $f(x)$ È UNA FUNZIONE QUADRATICA RISPETTO AD α ED È PUNTO UNICO RICONOSCIBILE AD UNA PAROLA. QUESTO SIGNIFICA CHE PRESENTA UN UNICO MINIMO LOCALE = GLOBALE PER CALCOLARE PUNTO IL PUNTO DI MINIMO SE CALCOLA $f'(x)$ E SI UGUALE A ZERO:

$$f'(\alpha) = \nabla f(x^k)^T d_k + \alpha d_k^T Q d_k \Rightarrow \alpha^* = \frac{-\nabla f(x^k)^T d_k}{d_k^T Q d_k}$$

PUNTO PER UNA FUNZIONE QUADRATICA È POSSIBILE OTtenere UNA LINEA SEARCH ESATTA PERCHÉ SIANO IN CASO DI CALCOLARE IL PASSO OTTIMO α^*

RICERCA DI LINEA INESATTA

In questo caso l'obiettivo è ricercare un passo che verifichi le seguenti proprietà:

• $f(x^k + \alpha_k d_k) \leq f(x^k)$

oppure

$f(\alpha_k) \leq f(0)$

$$f(x^k + \alpha_k d_k) \leq f(x^k) - \epsilon_k(\alpha_k)$$

SUFFICIENTE
DECREMENTO
POSITIVO

CONVERGENZA DI ARMIJO

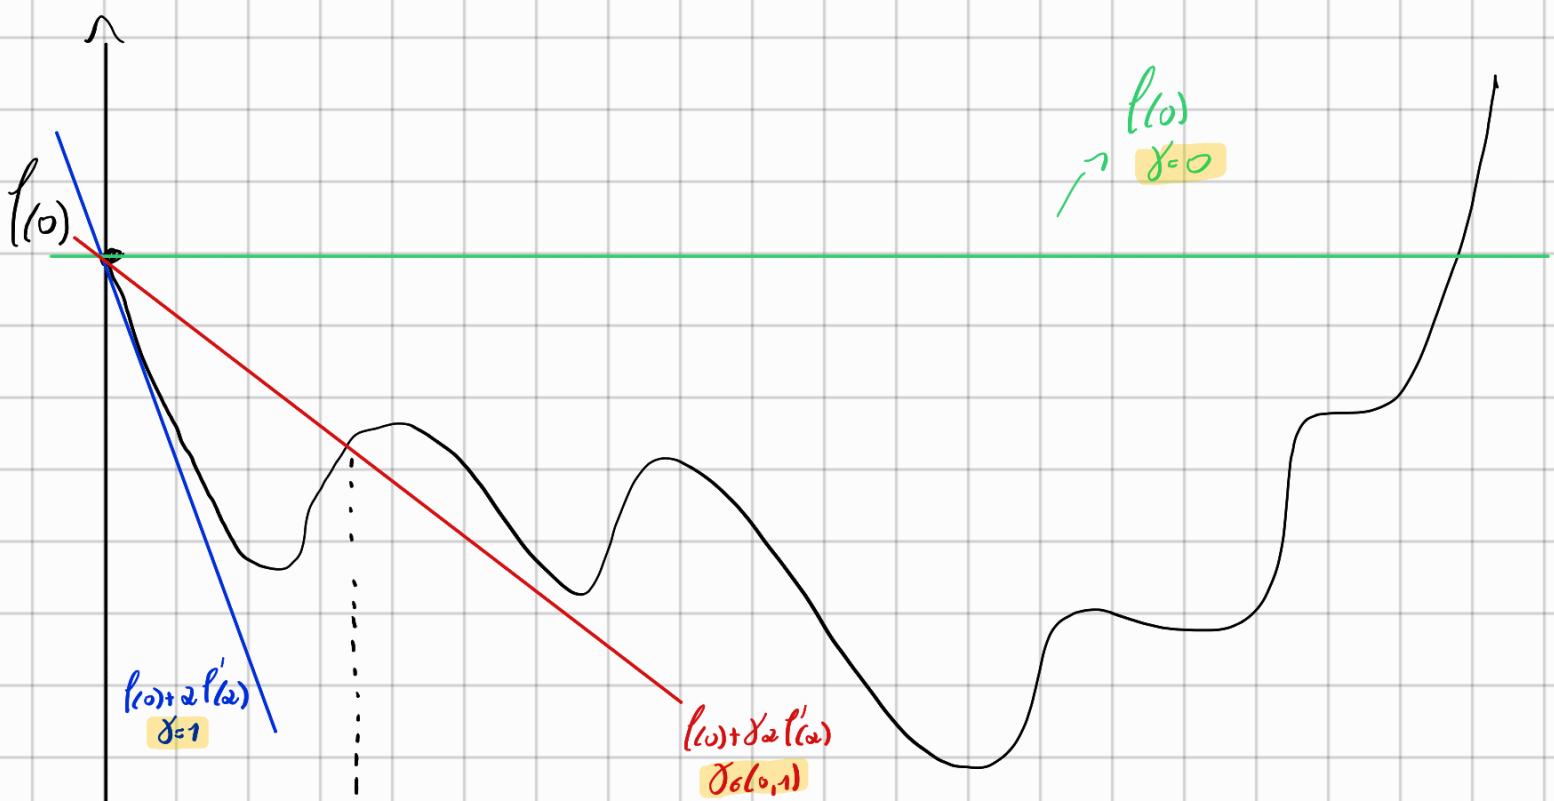
Dato $\delta_{\epsilon}(0,1) \in d_k$ t.c. $\nabla f(x^k)^T d_k < 0$ si ha che:

$$f(x^k + \alpha_k d_k) \leq f(x^k) + \delta \alpha_k \nabla f(x^k)^T d_k$$

POSSIAMO ANCHE SCRIVERE COME:

$$f(x^k) \leq f(x_0) + \delta \alpha_k f'(x)$$

SI STABILISCE CHE IL PASSO DEVE ESSERE SUFFICIENTEMENTE PICCOLO IN MODO CHE LA FUNZIONE OGGETTIVO DIMINUISCA IN MODO SIGNIFICATIVO MA NON NECESSARIAMENTE FINO AL SUO VALORE MINIMO!



Questo è l'intervallo
 di valori che soddisfano
 la condizione di
 Armijo

VEDIAMO L'ALGORITMO CHE DESCRIVE IL METODO DI Armijo

- DATI:
- x^k
- d_k t.c. $\nabla f(x^k)^T d_k \leq 0$
- $\delta_6(0,1)$
- $\beta_6(0,1)$
- $\alpha > 0$

→ Mentre fino a quando non è soddisfatta la condizione di Armijo

SIA $t = 0$

WHILE $(f(x^k + \alpha_t d_k) > f(x^k) + \gamma \alpha_t \nabla f(x^k)^T d_k)$

$$\begin{aligned} \alpha_{t+1} &= \beta \alpha_t \\ t &= t+1 \end{aligned}$$

END WHILE

TERMINAZIONE FINITA DEL METODO DI Armijo

SUPPONIAMO CHE

$$\nabla f(x^k)^T d_k \leq 0, \alpha > 0,$$

allora:

perché della
condizione Armijo
SERVONO PER ABBRACCIO
IL POSSO

$$\beta_6(0,1), \delta_6(0,1),$$

① L'ALGORITMO DI Armijo PRODUCE, IN UN NUMERO FINITO DI PASSI,
UN CERTO VALORE x^* CHE SODDISFA LA CONDIZIONE DI Armijo.

② VARE CON TAU:

(1) SI FERM AL PASSO INIZIALE

a) $\alpha_K = \alpha_{\tau_0}$

b) $\alpha_K \leq \beta \alpha_0 \in f(x^k + \frac{\alpha_k}{\beta} d_k) > f(x^k) + \frac{\alpha_k}{\beta} \nabla f(x^k)^T d_k$

\Downarrow

ABBIANO FAITO
ALTRIO UN PASSO

Dim:

① SUPponiamo per assurdo che la tesi che vogliamo dimostrare sia falsa
sia così che esiste $t \in \{0, 1, \dots\}$ e necessario che $\alpha_t = \beta^t \alpha_0$:

$$f(x^k + \underbrace{\beta^t \alpha_0 d_k}_{\gamma d_k}) > f(x^k) + \gamma \beta^t \alpha_0 \nabla f(x^k)^T d_k$$

$$\Rightarrow f(x^k + \beta^t \alpha_0 d_k) - f(x^k) > \gamma \beta^t \alpha_0 \nabla f(x^k)^T d_k$$

\downarrow
SI DIVIDE PER
 $\beta^t \alpha_0$

$$\Rightarrow \underbrace{\frac{f(x^k + \beta^t \alpha_0 d_k) - f(x^k)}{\beta^t \alpha_0}}_{\gamma} > \gamma \nabla f(x^k)^T d_k$$

per $t \rightarrow \infty$ tende
alla stessa direzione
 $\nabla f(x^k)^T d_k$ perché
 $\beta^t \rightarrow 0$ perché $\beta \in (0, 1)$

$$\Rightarrow \nabla f(x^k)^T d_k \geq \gamma \nabla f(x^k)^T d_k \rightarrow \underbrace{(1-\gamma)}_{<0} \nabla f(x^k)^T d_k \geq 0$$

PERCHÉ PER L'
ASSURDO, NON SODDISFA
ARVO!

ASSURDO! □

2

Per come è strutturato l'algoritmo si incontra o SI ACCETTA
SUBITO IL PASSO INIZIALE (vce ②) oppure è MENOSCA
RIVEDERÀ OGNI PASSO, avendo $\lambda_k = 2\alpha$.
Inoltre, nella PENULTIMA ITERAZIONE il controllo della condizione
di Arvo non viene superato poiché è l'ultimo passo in cui
può effettivamente accadere la riveduta, quindi:

$$f(x^k + \frac{\lambda_k}{2} d_k) > f(x^k) + \gamma \frac{\lambda_k}{2} \nabla f(x^k)^T d_k$$

□

CONVERGENZA DEL METODO LINE-SEARCH CON RICERCA DI Arvo

sia $f \in C^1(\mathbb{R}^n)$, $x^k \in \mathbb{R}^n$ tc: Lo è compreso e sia $\{x^k\}$ la
sequenza prodotta dall'algoritmo, tale che:

$$\nabla f(x^k)^T d_k \leq -\gamma_k$$

SE

$$\lambda_k(k) \geq \frac{1}{\|d_k\|} \delta \left(\frac{|\nabla f(x^k)^T d_k|}{\|d_k\|} \right)$$

con δ di forzamento, allora:

IN PRACTICA SIGNIFICA CHE IL PASSO
INIZIALE DEVE ESSERE SIGNIFICATIVO

$$a) \underline{f(x^{k+1}) < f(x^k)} \rightarrow \text{as sequenze prodotti 6 monoton} \text{ non crescente}$$

$$b) \lim_{k \rightarrow \infty} \frac{\|\nabla f(x^k)^T d_k\|}{\|d_k\|} = 0 \rightarrow \text{se ha convergenza a punti stabili}$$

Dim:

(a) per le proprietà di Newto vale che:

$$\begin{aligned} f(x^{k+1}) &= f(x^k + \alpha_n d_n) \leq f(x^k) + \underbrace{\gamma \alpha_n}_{>0} \underbrace{\nabla f(x^k)^T d_n}_{<0} \\ &\leq f(x^k) \quad \square \end{aligned}$$

Newto come si sta:

(b) consideriamo $\boxed{f(x^k) - f(x^{k+1}) \geq -\gamma \alpha_n \|\nabla f(x^k)^T d_k\|}$

da cui arriviamo alle formule di Newto.

$$\Rightarrow f(x^k) - f(x^{k+1}) \geq -\gamma \alpha_n \underbrace{\|\nabla f(x^k)^T d_k\|}_{>0}$$

poiché $\nabla f(x^k)^T d_k$
è negativa e
può essere 1. 1

$$= \gamma \alpha_n \|\nabla f(x^k)^T d_k\|$$

posso scrivere
il meno

$$= \gamma \alpha_n \|d_k\| \cdot \frac{\|\nabla f(x^k)^T d_k\|}{\|d_k\|}$$

$$= \gamma \alpha_n \|d_k\| \cdot \frac{|\nabla f(x^k)^T d_k|}{\|d_k\|} > 0$$

quindi ottieniamo che $f(x^k) - f(x^{k+1}) \geq \gamma \alpha_n \|d_k\| \frac{|\nabla f(x^k)^T d_k|}{\|d_k\|} > 0$

SE CONSIDERAMO UNA SEQUENZA $\{f(x^k)\}$ SU UNA CIE PUNTI
 E' DECRESCENTE PER IL PUNTO α .

SUPPIAMO INOLTRE CHE $\{x^k\}$ CONVERGA PER HP, PUNTO $\{f(x^k)\}$ AMBOLE
 UNITE FINITO.

SE CONSIDERAMO $\lim_{k \rightarrow \infty} f(x^k) - f(x^{k+1}) \geq \gamma_{2n} \|d_k\| \frac{|\nabla f(x^k)^T d_k|}{\|d_k\|}$ SU UNA CIE:

$$\left\langle \bar{f} - \bar{f} \right\rangle \geq \lim_{n \rightarrow \infty} \gamma_{2n} \|d_k\| \frac{|\nabla f(x^k)^T d_k|}{\|d_k\|} > 0$$

\Rightarrow PER IL TEOREMA DEI CRITERI SI HA CHE CI E'

$$\lim_{n \rightarrow \infty} \gamma_{2n} \|d_k\| \frac{|\nabla f(x^k)^T d_k|}{\|d_k\|} = 0$$

SE CONSIDERAMO UNA SEQUENZA

$$\left\{ \frac{|\nabla f(x^k)^T d_k|}{\|d_k\|} \right\} \subset \left\{ \frac{|\nabla f(x^k)^T d_k|}{\|d_k\|} \right\}$$

SU UNA CIE:

$\{x^k\} \subset \{x\}$ E' UNTA

\Rightarrow

$\{|\nabla f(x^k)|\}$ E' UNTA

$\nabla f(x^k)$ E' CONTINUA

$$\left\{ \frac{d_k}{\|d_k\|} \right\}$$

$$\left\{ |\nabla f(x^k)| \right\}$$

$$\left\{ \begin{array}{l} \text{null} \\ \text{non null} \end{array} \right\}, \quad \left\{ \begin{array}{l} \text{null} \\ \text{non null} \end{array} \right\}$$

6 POSSIBILI PUNTI DI ACCUMULAZIONE

ASSUMO ORA CHE (b) SIA FALSA! $\exists K \subseteq \{0, 1, \dots\}$ TALE CHE:

$$\lim_{\substack{n \rightarrow \infty \\ n \in K}} \frac{\nabla f(x^k)^T d_n}{\|d_n\|} = -\mu < 0$$

\rightarrow punto di attrazione

G POSSIAMO INVECE NOTARE CHE $\{x^n\}$ È UNA SOTTOSERIE

$\left\{ \frac{d_n}{\|d_n\|} \right\}$, PERCIÒ ESISTE UNA SOTTOSERIE $K_1 \subseteq K$ TC:

$$x^k \xrightarrow{k \in K_1} \bar{x} \in \frac{\mathbb{R}^n}{\|d_n\|} \xrightarrow{n \in K_1} \bar{J}$$

G PER LA CONTINUITÀ DEL GRADIENTE POSSO SCRIVERE:

$$\lim_{\substack{n \rightarrow \infty \\ n \in K_1}} \frac{\nabla f(x^k)^T d_n}{\|d_n\|} = \nabla f(\bar{x})^T \bar{J} = -\mu < 0$$

$$\Rightarrow \lim_{\substack{n \rightarrow \infty \\ n \in K_1}} \gamma_{2n} \|d_n\| \frac{\nabla f(x^k)^T d_n}{\|d_n\|} \geq 0 \Rightarrow \lim_{\substack{n \rightarrow \infty \\ n \in K_1}} \gamma_{2n} \|d_n\| = 0$$

$\rightarrow \mu \neq 0$

SI POSSONO PUNZ DISTINVERE DUE CASI:

① $\exists \bar{K} \in K_1$ tc: $\forall_{\bar{K}} K_1 \subseteq K_2, \bar{K}$ VALORE CNE:

$$\lambda_K = \lambda_0(K)$$

② $\exists K_2 \subseteq K_1$ tc: $\lambda_K < \lambda_0(K)$ $\forall_{\bar{K}} K_2$

ANALIZZIAMO IL PRIMO CASO:

$$1) \lambda_K \|d_K\| = \lambda_0(K) \|d_K\| \geq \frac{1}{\|d_K\|} \sigma \left(\frac{|\nabla f(x^u)^T d_K|}{\|d_K\|} \right) \|d_K\|$$

≥ 0 PER DEFINIZIONE DI σ

$$\text{PUNTO } \lambda_K \|d_K\| \geq \sigma \left(\frac{|\nabla f(x^u)^T d_K|}{\|d_K\|} \right) \geq 0$$

$\underbrace{\phantom{\lambda_K \|d_K\| \geq \sigma \left(\frac{|\nabla f(x^u)^T d_K|}{\|d_K\|} \right) \geq 0}}$

$\hookrightarrow 0$ PER IL TEOREMA DI CARATHEODORY

$$\text{MA SE } \sigma(\cdot) \rightarrow 0 \text{ ALLORA } \frac{|\nabla f(x^u)^T d_K|}{\|d_K\|} \xrightarrow[\substack{K \rightarrow \infty \\ u \in K_1}]{} 0$$

\hookrightarrow ASSURDO!

$$= |\nabla f(x^u)^T d_K| \xrightarrow[\substack{K \rightarrow \infty \\ u \in K_1}]{} 0$$

ma anche $\|\nabla f(x^k)\| \rightarrow 0$

\Rightarrow punto ① non può essere vero e punto vero ②, ovvero

$$\lambda_n < \lambda_0(\mu) \text{ fissa } K_2$$

punto $\int f(x^k + \frac{\lambda_n}{2} d_n) > f(x^k) + \frac{\lambda_n}{2} \nabla f(x^k)^T d_n$ per le proprietà

DEL METODO DI NEWTON. consideriamo adesso IL TEOREMA DELLA MEDIA:

$$\int f(x^k + \frac{\lambda_n}{2} d_n) = f(x^k) + \frac{\lambda_n}{2} \nabla f(\xi_n)^T d_n$$

con $\xi_n = x^k + t_k \frac{\lambda_n}{2} d_n$ per $t \in (0, 1)$

SI HA ALLORA CHE:

$$\frac{\lambda_n}{2} \nabla f(\xi_n)^T d_n = \int f(x^k + \frac{\lambda_n}{2} d_n) - f(x^k) > \frac{\lambda_n}{2} \nabla f(x^k)^T d_n$$

$$\Rightarrow \frac{\lambda_n}{2} \nabla f(\xi_n)^T d_n > \frac{\lambda_n}{2} \nabla f(x^k)^T d_n$$

$$\Rightarrow \frac{\nabla f(\xi_n)^T d_n}{\|d_n\|} > \frac{\nabla f(x^k)^T d_n}{\|d_n\|}$$

Per il $\lim_{\substack{h \rightarrow 0 \\ h \in K_2}} s_j$ ho che $\frac{du}{\|du\|} \rightarrow \bar{J}$, $x^h \rightarrow \bar{x}$

$$\text{E per il } \lim_{\substack{h \rightarrow 0 \\ h \in K_2}} E_h = \lim_{\substack{h \rightarrow 0 \\ h \in K_2}} x^h + t_h \underbrace{\frac{\partial u}{\partial} du}_{(q_1)} = \bar{x}$$

puoi ottenere che $\nabla f(\bar{x})^T \bar{J} \geq \lambda \nabla f(\bar{x})^T \bar{J}$ ovvero che

$$(1 - \lambda) \nabla f(\bar{x})^T \bar{J} \geq 0 \quad \Leftrightarrow \text{assurdo!}$$

\square

METODO DEL GRADIENTE

Dato $x^0 \in \mathbb{R}^n$ l'algoritmo è:

$$k=0$$

while $(\nabla f(x^k) \neq 0)$:

- Si pone $d_k = -\nabla f(x^k)$

- Si calcola α_k con il metodo di Amijo

- Si pone $x^{k+1} = x^k - \alpha_k \nabla f(x^k)$

. $u = u + 1$

END WHILE

SIA $f \in C^1(\mathbb{R}^n)$ E SUA X^{*} ∈ \mathbb{R}^n TALE CHE x^* È COMPATO,
ALLORA IL METODO DEL GRADIENTE GENERA UNA SEQUENZA DI
SOLUZIONI $\{x^k\}$ CHE AMMETTE PUNTI DI ACCUMULAZIONE, OGNISSA DEI
PUNTI RISULTA ESSERE UN PUNTO STAZIONARIO

↳ PUNTI SOLUZIONI LI PUOSSERI CONSIDERARE SOLO
ACCORDO ALL'ACCUMULAZIONE

INSOMMA SI HA CHE IL METODO DEL GRADIENTE PRESENTA UN
TASSO DI CONVERGENZA SUBLINEARE

$$\hookrightarrow \lim_{k \rightarrow \infty} \frac{\|x^{k+1} - x^*\|}{\|x^k - x^*\|} = 1$$

DEFINIZIONE FUNZIONE FORTEMENTE CONVESSA

SI DICE CHE UNA FUNZIONE $f: \mathbb{R}^n \rightarrow \mathbb{R}$ È FORTEMENTE CONVESSA

SE ESISTE UNA FUNZIONE $g: \mathbb{R}^n \rightarrow \mathbb{R}$ E $\mu > 0$ TAU CHE:

$$f(x) = g(x) + \mu \|x\|^2 \quad \forall x \in \mathbb{R}^n$$

PUNTO SE f È UNA FUNZIONE FORTEMENTE CONVESSA, ALLORA
IL METODO DEL GRADIENTE PRESENTA UN TASSO DI CONVERGENZA
LINEARE

DEFINIZIONE

$$\hookrightarrow \lim_{k \rightarrow \infty} \frac{\|x^{k+1} - x^*\|}{\|x^k - x^*\|} = c \in (0, 1)$$

METODO DEL GRADIENTE A PASSO COSTANTE

DEFINIAMO PRIMA LA SEGUENTE IPOTESI:

SIA $f \in C^2(\mathbb{R}^n)$ E SIA ∇f LIPSCHITZ-CONTINUO DI COSTANTE $L > 0$:

$$\forall x, y \in \mathbb{R}^n: \|\nabla f(x) - \nabla f(y)\| \leq L \|x - y\|$$

E SE LA FUNZIONE $f \in C^2(\mathbb{R}^n)$ POSSIAMO ANCHE SCRIVERE CHE:

$$|\mu^T \nabla^2 f(x) \mu| \leq \|\mu\|^2 \quad \forall x, \mu \in \mathbb{R}^n$$

QUINDI, CON QUESTE IPOTESI ($f \in C^2(\mathbb{R}^n)$ E ∇f LIPSCHITZ-CONTINUO) POSSIAMO DEFINIRE IL METODO DEL GRADIENTE A PASSO COSTANTE, DOVE VIENE CHE:

$$x^{k+1} = x^k - \frac{1}{L} \nabla f(x^k)$$

$$\hookrightarrow \text{z. n. } \frac{1}{L} \text{ costante}$$

E VEDI CHE, $\forall d, x_0 \in \mathbb{R}^n$ E $\forall t > 0$:

$$f(x+td) \leq f(x) + t \nabla f(x)^T d + t^2 L \frac{\|d\|^2}{2}$$

Dim:

considerando la formula di Taylor:

$$\begin{aligned} f(x+td) &= f(x) + t \nabla f(x)^T d + \frac{t^2}{2} d^T \nabla^2 f(\gamma) d \text{ per qualche } \gamma \in \mathbb{R}^n \\ &\leq f(x) + t \nabla f(x)^T d + \frac{t^2}{2} \|d^T \nabla^2 f(\gamma) d\| \\ &\leq f(x) + t \nabla f(x)^T d + t^2 L \frac{\|d\|^2}{2} \quad \square \end{aligned}$$

SIA $f: \mathbb{R}^n \rightarrow \mathbb{R}$ TALE CHE $\boxed{f \in C^2(\mathbb{R})}$ e $\boxed{\nabla f}$ LIPSCHEZ-CONTINUA

1) COSTRUIRE L , $x^0 \in \mathbb{R}^n$ TALE CHE $\boxed{\nabla f}$ E' COMPRESO, NELLO IL MATEMATICO

DEL GRADIENTE CON PASSO $\boxed{\Delta u = \frac{1}{L} \nabla u}$ OTTIENE UNA SEQUENZA $\{x^u\}$ TC:

$$\textcircled{1} \quad \boxed{f(x^{u+1}) \leq f(x^u) - \frac{1}{2L} \|\nabla f(x^u)\|^2 \Delta u}$$

\textcircled{2} $\{x^u\}$ AI PUNTI DI ACCUMULAZIONE SISTEMI

Dim:

1)

$$\text{seguo } \nabla f(x^u) = d_u$$

$$f(x^{u+1}) = f(x) - \alpha_u d_u$$

$$\leq f(x) - \alpha_u d_u^T d_u + \frac{\alpha_u^2}{2} \|d_u\|^2$$

$$\text{M} \quad \underline{\alpha_u = \frac{1}{L}} \quad \text{E} \quad \underline{d_u = -\nabla f(x^u)}$$

$$\Rightarrow f(x^{u+1}) = f(x^u) - \frac{1}{L} \nabla f(x^u)^T \nabla f(x^u) + \frac{1}{L^2} \frac{1}{2} \|\nabla f(x^u)\|^2$$

$$= f(x^u) - \frac{1}{L} \|\nabla f(x^u)\|^2 + \frac{1}{2L} \|\nabla f(x^u)\|^2$$

$$= f(x^u) - \frac{1}{2L} \|\nabla f(x^u)\|^2 \quad \square$$

$$2) \quad f(x^{u+1}) - f(x^u) \leq -\frac{1}{2L} \|\nabla f(x^u)\|^2 < 0$$

$f(x^u)$ è monotona DECREScente

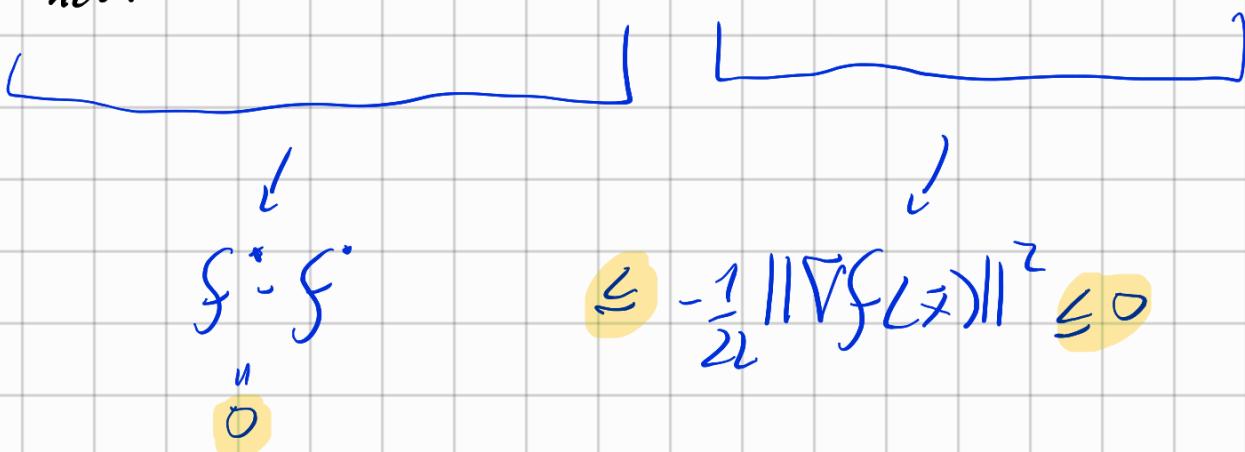
$\{x^u\} \subset S_0 \Rightarrow \exists$ punti di accumulazione

$\left\{ \Rightarrow f(x^u) \rightarrow f^*$ FINITO

PIÙ DI SIA X UN PUNTO PREVISTO TUTTO PERTO DI ACCUMULAZIONE.

CIOÈ $\exists n \in \{0, 1, \dots\}$ TALE CHE: $\lim_{\substack{n \rightarrow \infty \\ u \rightarrow 0}} x^u = \bar{x}$, ALLORA

$$\lim_{\substack{n \rightarrow \infty \\ u \rightarrow 0}} f(x^{u+1}) - f(x^u) \leq \lim_{\substack{n \rightarrow \infty \\ u \in \mathbb{N}}} -\frac{1}{2} \sum_{i \in \mathbb{N}} \|\nabla f(x^i)\|^2$$



$$\Rightarrow \|\nabla f(\bar{x})\| = 0 \quad \square$$

COMPRESSISSIONE NORMALE DI OTTIMIZZAZIONE

SOTTO LE SEGUENTI IPOTESI:

- f LINEARE INFERMIERTE DI f^*
- f CONVESA

IF E UPSCHITZ-CONST

DEFINITION

- an algorithm has an ITERATION ERROR of $O(h(u))$ SE

$$f(x^u) - f^* = O(h(u))$$

- its ITERATION COMPLEXITY is $O(\hat{h}(\varepsilon))$ SE!

$$\min \left\{ k \mid f(x^u) - f^* \leq \varepsilon \right\} = O(\hat{h}(\varepsilon))$$

VISUALISATION CONCERNING THE DUE PROCESS:

- SE NO $f(x^u) - f^* \approx \frac{1}{K}$ messen:

$$f(x^u) - f^* < \varepsilon \Rightarrow K > \frac{1}{\varepsilon} \Rightarrow K = O\left(\frac{1}{\varepsilon}\right)$$

- SE NO $f(x^u) - f^* \approx \frac{1}{K^2}$ messen:

$$f(x^k) - f^* \leq \varepsilon \Rightarrow H > \frac{1}{\sqrt{\varepsilon}} \Leftrightarrow H = O\left(\frac{1}{\sqrt{\varepsilon}}\right)$$

SI HA CHE IL COSTO DI OGNI CIFRA SIGNIFICATIVA DI PROBLEMA
NE CRESCHE IN MODO DA ESPONENZIALE CON IL NUMERO DI
ITERAZIONI!

ε	# CIFRE SIGNIFICATIVE $= \log\left(\frac{1}{\varepsilon}\right)$	COSTO PER RAGGIUNGERE IL NUMERO DI CIFRE SIGNIFICATIVE SE LO COSTO VARE $O\left(\frac{1}{\varepsilon}\right)$
0.1	1	10
0.01	2	100
0.001	3	1000

↓
exp

SE UN CERTO ALGORITMO PRESENTE IN $\varepsilon = O\left(\frac{1}{H}\right)$
OTTIME:

$$\lim_{H \rightarrow \infty} \frac{f(x^{H+1}) - f^*}{f(x^H) - f^*} \approx \lim_{H \rightarrow \infty} O\left(\frac{H}{H+1}\right) = 1$$

SI OTTENGONO ALLORA PASSI **SUBLINARI**. ANNOTAMENTE
SI OTTENGONO CUEI, CON $S > 0$:

NEWTON-GD

ITERATION COMPLEXITY

TIME

$$\mathcal{O}\left(\frac{1}{k}\right)$$

$$\mathcal{O}\left(\frac{1}{\epsilon}\right)$$

SUBLINEARE X

$$\mathcal{O}(P^k)$$

$$\mathcal{O}\left(\log \frac{1}{\epsilon}\right)$$

LINEARE ✓

$$\mathcal{O}(P^{2k})$$

$$\mathcal{O}\left(\log\left(\log \frac{1}{\epsilon}\right)\right)$$

SUPERLINEARE ✓

Proposizioni

Sono le seguenti ipotesi:

- $f \in C^2(\mathbb{R}^n)$
- ∇f è Lipschitz-continuo di costante L
- $x_0 \in \mathbb{R}^n$ t.c. L_0 è compatto
- $\alpha_k = \frac{1}{L} \|t_k\|$
- f convessa e minima f^* in x^*

Allora possiamo affermare che il metodo del gradiente costante genera una sequenza $\{x^k\}$ t.c.

$$f(x^k) - f^* \leq \frac{\|x^* - x^0\|^2}{k+1}$$

SINTESI DEL COMPLESSITÀ DEL METODO DEL GRADIENTE A PASSO COSTANTE δ $O(\frac{1}{\kappa}) \Leftrightarrow O(\frac{1}{\epsilon})$

Dimo:

nuovissimo che

$$f(x^{k+1}) \leq f(x^*) - \frac{\|\nabla f(x^k)\|^2}{2L}$$

E inoltre per ipotesi si ha che f è convessa, puoi:

$$f(x^*) \geq f(x^k) + \nabla f(x^k)^T (x^* - x^k)$$

$\hookrightarrow f(x^*)$ sia sulla linea tangente ad f passante per x^k e uguale in x^*

Possiamo quindi scrivere per 4 e 5:

$$f(x^{k+1}) \stackrel{4}{\leq} f(x^k) - \frac{1}{2L} \|\nabla f(x^k)\|^2 \stackrel{5}{\leq} f(x^*) - \nabla f(x^k)^T (x^* - x^k) - \frac{1}{2L} \|\nabla f(x^k)\|^2$$

$$\Rightarrow f(x^{k+1}) - f(x^*) \leq - \nabla f(x^k)^T (x^* - x^k) - \frac{1}{2L} \|\nabla f(x^k)\|^2 \\ = \frac{L}{2} \left(- \frac{2}{L} \nabla f(x^k)^T (x^* - x^k) - \frac{1}{L^2} \|\nabla f(x^k)\|^2 \right)$$

$$= \frac{L}{2} \left(- \frac{2}{L} \nabla f(x^k)^T (x^* - x^k) - \frac{1}{L^2} \|\nabla f(x^k)\|^2 + \|x^* - x^k\|^2 - \|x^* - x^k\|^2 \right)$$

$$= \frac{L}{2} \left(\|x^* - x^k\|^2 - \underbrace{\left(\|x^* - x^k\|^2 + \frac{2}{L} \nabla f(x^k)^T (x^* - x^k) + \frac{1}{L^2} \|\nabla f(x^*)\|^2 \right)}_{\Delta} \right)$$

NOTAMOS QUE SE PUEDE $(x^* - x^k) = \alpha \in \frac{1}{L} \nabla f(x^k) + b$ OTROAS

$$\|a+b\|^2 = a^T a + b^T b + 2a^T b = \|a\|^2 + \|b\|^2 + 2a^T b$$

QUEMOS Δ DIVIENDO:

$$\|x^* - x^k\|^2 + \frac{1}{L} \|\nabla f(x^k)\|^2 + \frac{2}{L} \nabla f(x^k)^T (x^* - x^k)$$

CONTINUAMOS CON CADA UNA DE EXPRESIONES SI DIVIENDO:

$$= \frac{L}{2} \left(\|x^* - x^k\|^2 - \underbrace{\|x^* - x^k + \frac{1}{2} \nabla f(x^k)\|^2}_{\parallel} \right)$$

$$- \left(x^k - \frac{1}{L} \nabla f(x^k) \right) = -x^{k+1}$$

$$= \frac{L}{2} \left(\|x^* - x^k\|^2 - \|x^* - x^{k+1}\|^2 \right)$$

$$\Rightarrow f(x^{k+1}) - f(x^*) \leq \frac{L}{2} \left(\|x^* - x^k\|^2 - \|x^* - x^{k+1}\|^2 \right)$$

SE CONSIDERANO LE SOMME:

$$\sum_{t=0}^k f(x^{t+1}) - f(x^*) \leq \sum_{t=0}^n \zeta \left(\|x^* - x^t\|^2 - \|x^* - x^{t+1}\|^2 \right)$$

OBTENIMOS UNA SUCCESSIONE DI SOMME SEMPRE PIÙ
TERMINI ADVENTI:

$$= \sum \zeta \left(\|x^* - x^0\|^2 - \|x^* - x^{n+1}\|^2 \right) \leq \sum \zeta \left(\|x^* - x^0\|^2 \right)$$

PUNTI:

$$\sum_{t=0}^n f(x^{t+1}) - f(x^*) \leq \sum \zeta \left(\|x^* - x^0\|^2 \right)$$

MA $\{f(x^t)\}$ È UNA MONTAGNA DECRESCENTE DI PUNTI

$$f(x^{t+1}) \geq f(x^{t+1}) \quad \forall t \leq n$$

PUNTI

$$f(x^{t+1}) - f(x^*) \geq f(x^{u+1}) - f(x^*)$$

POSSIAMO INFINITAMENTE CONVERGERE ALLE:

$$\sum_{t=0}^K f(x^{t+1}) - f(x^*) \leq \sum_{t=0}^K f(x^{t+1}) - f(x^*) \leq L \left(\|x^* - x^0\|^2 \right)$$

↓ per CMB

$$f(x^{t+1}) \geq f(x^{k+1})$$

$$\forall t \leq k$$

DOVEMO:

$$(H+1)(f(x^{u+1}) - f(x^*)) \leq L \|x^* - x^0\|^2$$

$$\Rightarrow f(x^{u+1}) - f(x^*) \leq \frac{L \|x^* - x^0\|^2}{2(H+1)}$$

□

PROPOSIZIONE

NEL CASO IN CUI f È FORTEMENTE CONVESSA SI HA CHE
IL MODO DEL GRADIENTE È COMPLESSITÀ $O(\log \frac{1}{\epsilon})$ LINEARE

Inoltre, se consideriamo un problema di apprendimento supervisionato

$$\min_w L(w) + \lambda R(w)$$

Si fa così sì $L(w)$ è convessa, allora l'aggiunta del regolarizzatore rende la funzione obiettivo focalmente convessa e quindi migliora le prestazioni!

METODI CON TERMINI DI TIPO
MOMENTUM

1) METODO Henry-Ball

La formula di aggiornamento diventa:

$$x^{n+1} = x^n - \alpha_n \nabla f(x^n) + \beta (x^n - x^{n-1})$$

TERMINE CHE
DIPENDE DALLO
SPOSTAMENTO ALL'
ITERAZIONE
PRECEDENTE!

Il metodo si move verso combinazione tra l'antigradiente e la direzione dell'ultimo spostamento e può si può risolvere così:

$$\left\{ \begin{array}{l} Y^u = X^u - \alpha_u \nabla f(X^u) \\ X^{u+1} = Y^u + \beta (X^u - X^{u-1}) \end{array} \right.$$

$$\left\{ \begin{array}{l} V^u = X^u - X^{u-1} \\ X^{u+1} = X^u + V^u - \alpha_u \nabla f(X^u) \end{array} \right.$$

ESSENDO CHE IL METODO DEL GRADIENTE DIPENDE FORTEMENTE
DALLA SCelta DEL PUNTO INIZIALE, QUINDI PUR IL TERMINE

$$\beta = (X^u - X^{u-1})$$

RENDE AD EVITARE LE VARIOSCUESSIONI DOVUTE AD UN
CATTIVO PUNTO DI PARTENZA.



- Pro: - SE f È FORTEMENTE CONVessa ALLORA IL CONVERGENZA È GARANTITA. SE f È PIÙ DUREA MA NON È β POSSONO ESSERE SCELTI IN MODO OTTIMALE IN FORMA CAVUSA.



- Contro: NELL'ALGO GENERALMENTE NON SUPPIANO CHE SE β È DIVENTATO GRANDE DAI CAUSI IN CUI IL METODO NON CONVERGE ANCHE SOTTO IPOTESI DI REGOLARITÀ.

2) METODO DI NEWTON

Le formule di aggiornamento diventano:

$$x^{n+1} = x^n + \beta(x^n - x^{n-1}) - \alpha_n \nabla f(x^n + \beta(x^n - x^{n-1}))$$

Dove:

$$\begin{cases} v^n = \beta(x^n - x^{n-1}) \\ x^{n+1} = x^n + v^n - \alpha_n \nabla f(x^n + v^n) \end{cases}$$

$$\begin{cases} y^n = x^n - \alpha_n \nabla f(x^n + \beta(x^n - x^{n-1})) \\ x^{n+1} = y^n + \beta(x^n - x^{n-1}) \end{cases}$$

L'iterazione, con β scelto opportunamente, ha complessità

$O\left(\frac{1}{f_2}\right) \Leftrightarrow O\left(\frac{1}{f'_2}\right)$ nel caso di f convessa e affina

per le iterazioni del primo ordine!

SIA $P \in \mathbb{R}^{n \times m}$ SIMETRICA E D.P., ALLORA UN INSieme DI DIREZIONI d_0, d_1, \dots, d_{m-1} CON $m \leq n$ SONO DIREZIONI INSIEME DI DIREZIONI MIGLIAMENTE CONVOLUTE RISPETTO A P SE:

$$\forall i, j = 0, \dots, m-1 \text{ con } i \neq j: d_i^T P d_j = 0$$

SIA d_0, \dots, d_{m-1} INSieme DI DIREZIONI MIGLIAMENTE CONVolute, ALLORA d_0, \dots, d_{m-1} SONO LINEAMENTI INDEPENDENTI

Dim:

CONSIDERAMO UNA COMBINAZIONE LINEARE NON NULLA DI d_0, \dots, d_{m-1} :

$$\sum_{j=0}^{m-1} \alpha_j d_j = 0$$

SIA $i \in \{0, \dots, m-1\}$. Moltiplichiamo la combinazione lineare

per $d_i^T P$:

$$d_i^T P \sum_{j=0}^{m-1} \alpha_j d_j = 0$$

MA VOLE LI UN'EQN ID:

$$\sum_{j=0}^{m-1} \alpha_j d_i^T Q d_j = 0$$

PER I PRTGS SUPPSSMO CHE $d_i^T Q d_j = 0 \forall i \neq j$ POGLIO
MUTAMENTE CONCETTE. ALLORA:

$$\underbrace{\alpha_i d_i^T Q d_i}_> 0 \text{ POGLIO } Q \text{ E DEFINITA}$$

POSITIVA

Allora $\alpha_i = 0 \in$ POGLIO $i \in$ Sono scelti i numeri
 NUMERI SI HANNO CHE $\alpha_i = 0 \forall i = 0, \dots, m-1$, ALLORA LE DIREZIONI
 SONO LINEARMENTE INDEPENDENTI \square

Caso Problemi Quadratici

SIA $\min_{x \in \mathbb{R}^n} \frac{1}{2} x^T Q x - c^T x$ UN PROBLEMA QUADRATICO. IN QUESTO CASO

SUPPSSMO CHE, RAGGIUNTA LA SOLUZIONE OTTIMA, SI HA:

$$\nabla f(x^*) = Qx^* - c = 0$$

Se d_0, \dots, d_{n-1} sono direzioni mutuamente concave, e
punti sono anche univarianti indipendenti, si ha:
 \hookrightarrow punti sono ass. base!

$$x^* = \sum_{s=0}^{n-1} \alpha_s^* d_s$$

PUNTI $Q_{x^*} = \sum_{s=0}^{n-1} \alpha_s^* Q d_s$. Si considerano i punti:

$$d_i^T Q_{x^*} = \sum_{s=0}^{n-1} \alpha_s^* d_i^T Q d_s$$

$$= \underline{\alpha_i^* j_i^T Q d_i} \quad \text{per definizione delle direzioni}$$

allora, disponendo di $Q_{x^*} = c$ nell'ottimo

$$d_i^T c = \alpha_i^* j_i^T Q d_i$$

$$\Rightarrow \alpha_i^* = \frac{j_i^T c}{j_i^T Q d_i}$$

possiamo punti ricavare a sostituendo ottimi $x^* = \sum_{s=0}^{n-1} \frac{d_s^T c}{d_s^T Q d_s} d_s$

$s \in \Omega$ $\int_S Q ds = 0$

DIRETTAMENTE, SENZA PUNTI POSSANTI DELL'INVERSIONE DI Q PER
NUOVOVERE IL SISTEMA $Q_{x^* \in C}$!

OSSERVAZIONE

DIFFERENZA TRA IL PUNTO DI
ORIGINE E IL PUNTO INIZIALE

CONSIDERIAMO

$$x^* - x^o = \sum_{s=0}^{n-1} \Delta s$$

SE SCOMPOSSIAMO LA

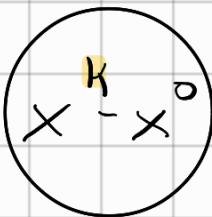
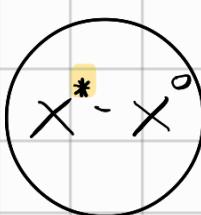
SUMMA SI OTTENGONO:

$$x^* = x^o + \Delta_0 d_0 + \Delta_1 d_1 + \Delta_2 d_2 + \dots + \Delta_{n-1} d_{n-1}$$

CHE RIASSUME NEL PROCESSO DI MOVIMENTO I FATTORI

$$x^* = x^o + \sum_{s=0}^{n-1} \Delta_s d_s$$

PENSAMO ALLORA $x^* - x^o$ E $x^k - x^o$. VEDIAMO:



$$1) d_n^T Q (x^k - x^o) = d_n^T Q \sum_{s=0}^{n-1} \Delta_s d_s = \sum_{s=0}^{n-1} \Delta_s d_n^T Q d_s = 0$$

$$2) d_n^T Q (x^* - x^o) = d_n^T = \sum_{s=0}^{n-1} \Delta_s d_n^T Q d_s = d_n^T$$

$$\frac{d_u \Psi(x - x^*)}{s=0} = \sum_{k=1}^n d_k \Psi(x^k - x^*)$$

secondo CG:

$$\alpha_u = \frac{d_u^T \Psi(x^* - x^u)}{d_u^T Q d_u} = \frac{d_u^T \Psi(x^* - x^u)}{d_K^T Q d_u} + \frac{d_u^T \Psi(x^u - x^*)}{d_u^T Q d_u}$$

$$= \frac{d_u^T (\Psi_{x^*} - \Psi_{x^u})}{d_u^T Q d_u} = \frac{d_u^T (C - Q x^u)}{d_u^T Q d_u} = \boxed{-\frac{d_u^T \nabla f(x^u)}{d_u^T Q d_u}}$$

Possò ottimizzare per
una direzione nel caso quadratico!

E, come si ottiene

$$\boxed{\nabla f(x^u) = g_u} \text{ suff.}$$

$$\boxed{x^{u+1} = x^u - \frac{g_u^T g_u}{d_u^T Q d_u} d_u}$$

CHE È IL METODO DELLE DIREZIONI CONVEGNE

PROVETA' DI CONVERGENZA FINITA PER IL METODO DELLE DIREZIONI CONVEGNE

SIA $\alpha_0, \dots, \alpha_{n-1}$ DIREZIONI MIGLIORAMENTE CONVOLTE A SIA
 $x^* \in \Omega^n$ CON:

$$x^{k+1} = x^k + \alpha_k d_k$$

CON $\alpha_k = \frac{-d_k^T g_k}{d_k^T P d_k}$, ALLORA:

1) \forall_k VICE $g_k^T d_i = 0 \quad \forall i = 0, \dots, n-1$

2) $\exists m \leq n$ EC: $x^m = x^*$ → ALLORA SI RIESCE A TROVARE LA SOLUZIONE OTTIMA GSARIA IN UN NUMERO FINITO DI PASSI!

DIM

1) SIA $i \in \{0, \dots, n-1\}$, ALLORA:

i-ESIMO PASSO
PUNTO DI K

$$x^k = x^i + \sum_{s=i}^{k-1} \alpha_s d_s$$

$\Rightarrow g_k^T d = (P x^{k-c})^T d = \left(P x^i + \sum_{s=i}^{k-1} \alpha_s (P d_s - c) \right)^T d$

$$= (P x^{k-c})^T d + \sum_{s=i}^{k-1} \alpha_s d_s^T P d_s$$

$$\begin{aligned}
 &= g_i^T d_i + \underbrace{\alpha_j d_i^T Q d_i}_{\text{blue}} \\
 &= g_i^T d_i - \frac{d_i^T g_i}{d_i^T Q d_i} d_i^T Q d_i \\
 &= g_i^T d_i - \alpha_j g_i^T = 0 \quad \square
 \end{aligned}$$

2)

SUPPOSSIAMO DI AVERE ESEGUITO N ITERAZIONI. ABBIAMO QUINDI OTTENUTO X^n TALE CHE:

$$g_n^T d_i = 0 \quad \forall i = 0, \dots, n-1$$

ovvero il gradiente è perpendicolare ad n direzioni che sono versamenti indipendenti, ovvero che costituiscono una base, nulla deve essere $\boxed{g_n \neq 0}$ ovvero:

$$\boxed{Q_{X^n} c = 0} \Rightarrow \boxed{X^n = X^*} \quad \square$$

METODO DEL GRADIENTE CONIUGATO

È IL METODO MIGLIORATO NEI USO DI FUNZIONI QUADRATICHE E SI USA SPESO PER LA RISOLUZIONE DI SISTEMI LINEARI CON Q SIMMETRICA E DEFINITA POSITIVA.

$x^0 \in \mathbb{R}^n$, $d_0 = -g_0$, $k=0$

WHILE ($\|g_k\| \neq 0$):

$$\cdot \text{calcola } \alpha_k = \frac{\|g_k\|^2}{d_k^T P d_k} = \frac{g_k^T d_k}{d_k^T P d_k}$$

$$\cdot x^{k+1} = x^k + \alpha_k d_k$$

$$\cdot \beta_{k+1} = \frac{\|g_{k+1}\|^2}{\|g_k\|^2}$$

$$\cdot d_{k+1} = -g_{k+1} + \beta_{k+1} d_k$$

$$\cdot k=k+1$$

END WHILE

Dove possiamo notare che:

$$g_{k+1} = Q(x^{k+1} - c) = Q(x^k + \alpha_k d_k - c)$$

$$= Q(x^k - c + \alpha_k Q d_k)$$

$$= g_k + \alpha_k Q d_k$$

Nel caso volgessimo applicare passo dopo passo nel caso

GENERALI DOBBIAMO FARLE ALCUNE MODIFICHE:

In particolare occorre modificare il criterio del passo per non abbiammo più la garanzia del passo ottimo (TACI DE) problema preventivo.

$$\|g_n\| \leq \epsilon$$

per questo occorre la scelta del passo in base a garanzie che:

$$d_{n+1}^T g_{n+1} < 0$$

Dove

$$d_{n+1}^T g_{n+1} = - \|g_{n+1}\|^2 + \beta_n d_n^T g_{n+1}$$

quando non basa usare la condizione di Armijo non occorre introdurre:

Condizioni di Wolfe

- Condizione debole:

garantisce che il passo scelto riduci in modo sufficiente il valore della funzione obiettiva

$$f(x^n + \alpha_n d_n) \leq f(x^n) + \alpha_n \nabla f(x^n)^T d_n$$

$$\nabla f(x^n + \alpha_n d_n)^T d_n \geq \nabla f(x^n)^T d_n \delta$$

$\delta \in (0, 1)$

$x \in \mathbb{R}^n$

$$f(x_n)$$

$$f'(0)$$

$$O(0, \varepsilon)$$

- Convergenza Forzata:

garantisce che il passo scelto non scavalca l'ottimo

$$\cdot f(x^n + \lambda u) \leq f(x^n) + \gamma \lambda u \quad \nabla f(x^n)^T u$$

$$\cdot |\nabla f(x^n + \lambda u)^T u| \leq \delta |\nabla f(x^n)^T u|$$

Più strettamente garantiscono che IL PASSO SCEGLIO MANTIENE IL PROGRESSO VERSO L'OTTIMO, MA ALLO STESSO TEMPO CHE NON SIA TROPPO LUNGO

METODO DI NEWTON

È UN METODO DEL II° ORDINE, DOVE È QUASI DISPONIBILE
ANCHE IL CALCOLO DELLA MATRICE NESSIMA $\nabla^2 f$:

SE CONSIDERIAMO L'APPROXIMAZIONE AL SECONDO ORDINE DI x^n :

$$m_n(x) = f(x^n) + \nabla f(x^n)^T (x - x^n) + \frac{1}{2} (x - x^n)^T \nabla^2 f(x^n) (x - x^n)$$

SE L'NESSIMA È DEFINITA POSITIVA, ALLORA $m_n(x)$, ESSENDO UNA FUNZIONE QUADRATICA CON $\nabla^2 f$ DP, È STRETTAMENTE CONVESSA. SI PUÒ PENSARE DI CONVOLGENDO IL MINIMO PROSPETTO

$$\nabla_{\mathbf{m}_H}(\hat{x}) = \mathbf{0}$$

*calcolo rispetto
ad x*

$$\Rightarrow \nabla_{\mathbf{m}_H}(\hat{x}) = \nabla f(x^u) + \nabla^2 f(x^u)(\hat{x} - x^u) = \mathbf{0}$$

$$\Rightarrow \nabla^2 f(x^u)(\hat{x} - x^u) = -\nabla f(x^u)$$

$$\Rightarrow \hat{x} - x^u = -[\nabla^2 f(x^u)]^{-1} \nabla f(x^u)$$

$$\Rightarrow \hat{x} = x^u - [\nabla^2 f(x^u)]^{-1} \nabla f(x^u)$$

*approssimazione
dell'ottimo*

Si ottiene quindi la **formula di aggiornamento del metodo di Newton**:

$$x^{u+1} = x^u - [\nabla^2 f(x^u)]^{-1} \nabla f(x^u)$$

Che può essere intendersi come la classica formula:

$$x^{u+1} = x^u + \alpha_u d_u \text{ con } \alpha_u = 1$$

$$d_u = -[\nabla^2 f(x^u)]^{-1} \nabla f(x^u)$$

non ottiene come il metodo del gradiente!

PROPRIETÀ DI CONVERGENZA LOCALE DI NEWTON

Sia $\mathcal{F} \in C^2(\mathbb{R}^n)$ con $x^* \in \mathbb{R}^n$ tale che $\nabla f(x^*) = 0$ e sia

$\nabla^2 f(x^*)$ non singolare, non zero tale che $\forall x \in B_\epsilon(x^*)$ la sequenza

$\{x^u\}$ ottenuta dall'aggiornamento: $x^{u+1} = x^u - [\nabla^2 f(x^u)]^{-1} \nabla f(x^u)$

SODDISFA LE SEGUENTI PROPRIETÀ:

1. $\{x^k\} \subseteq B_\epsilon(x^*)$

→ molti punti di accumulazione nell'intorno dell'ottimo

2. $\lim_{k \rightarrow \infty} x^k = x^*$ → convergenza ottimale ad un punto di minimo!

3. $\lim_{h \rightarrow \infty} \frac{\|x^{k+1} - x^*\|}{\|x^k - x^*\|} = 0$ → passo superlineare

→ se $\nabla^2 f$ è lipschitz-continua allora
il passo è quadrattico

CONVERGENZA
LOCALE!

Dim: ①, ②

Vogliamo dimostrare che $\{x^k\} \subseteq B_\epsilon(x^*)$ se $x^k \in B_\epsilon(x^*)$ per qualche k con $x^k \rightarrow x^*$

ricorriamo prima il TEOREMA DELLA MEDIA INTEGRALE:

$$\int_a^b f'(x) dx = f(b) - f(a)$$

$$F: \mathbb{R}^n \rightarrow \mathbb{R}^m \text{ su } \forall x, y: F(x) - F(y) + \int_0^1 J_F\left(y+t(x-y)\right)(x-y) dt$$

$\hookrightarrow J_F: \mathbb{R}^n \rightarrow \mathbb{R}^{m \times n}$

essendo per ip, $\nabla^2 f(x)$ non singolare, allora $\exists \varepsilon > 0$,

$\mu > 0$ tale che:

$$\|[\nabla^2 f(x^*)]^{-1}\| \leq \mu \quad \forall_{x \in B_\varepsilon(x^*)}$$

insieme, essendo $\int_0^1 C^2(\mathbb{R}^n)$ allora $\exists \varepsilon \leq \varepsilon_1$ con $\delta > 0$

talche:

$$\| \nabla^2 f(x^k) - \nabla^2 f(y) \| \leq \frac{\delta}{\mu} \quad \forall_{x \in B_\varepsilon(x^k)}$$

supponiamo allora che $x^k \in B_\varepsilon(x^*)$ e, per induzione, che

$x^k \in B_\varepsilon(x^*)$ con x^u ottenuto dopo x^k .

Dimostriamo allora che $x^{k+1} \in B_\varepsilon(x^*)$:

$$x^{k+1} - x^k = x^k - \left[\nabla^2 f(x^k) \right]^{-1} \nabla f(x^k) - x^*$$

moltiplico per J_F

$$= \boxed{[\nabla^2 f(x^u)]^{-1} [\nabla f(x^u) + [\nabla^2 f(x^u)] [\nabla f(x^*)]} (x^u - x^*)$$

$$= -[\nabla^2 f(x^u)]^{-1} \left(\nabla f(x^u) - \nabla^2 f(x^u)(x^u - x^*) \right)$$

$$= -[\nabla^2 f(x^u)]^{-1} \left(\nabla f(x^u) - \underbrace{\nabla f(x^*)}_{\text{per hp}} - \nabla^2 f(x^u)(x^u - x^*) \right)$$

$$\Rightarrow \|x^{u+1} - x^*\| = \|[\nabla^2 f(x^u)]^{-1} (\nabla f(x^u) - \nabla f(x^*) - \nabla^2 f(x^u)(x^u - x^*))\|$$

$$\leq \underbrace{\|[\nabla^2 f(x^u)]^{-1}\|}_{\leq \mu} \cdot \| \nabla f(x^u) - \nabla f(x^*) - \nabla^2 f(x^u)(x^u - x^*) \|$$

$$\leq \mu \| \nabla f(x^u) - \nabla f(x^u) - \nabla^2 f(x^u)(x^u - x^*) \| \quad \text{4}$$

USUABILMOS SOBRE OS TEOREMAS DO LA MÉDIA INTEGRAL:

$$\boxed{\nabla f(x^u) = \nabla f(x^*) + \int_0^1 \nabla^2 f(x^* + t(x^u - x^*)) (x^u - x^*) dt}$$

$$\Rightarrow \Delta = \mu \left\| \int_0^1 \nabla^2 f(x^* + t(x^u - x^*)) (x^u - x^*) dt - \nabla^2 f(x^u)(x^u - x^*) \right\|$$

$$= \mu \left\| \int_0^1 \nabla^2 f(x^* + t(x^u - x^*)) (x^u - x^*) - \nabla^2 f(x^u)(x^u - x^*) dt \right\|$$

$$= \mu \left\| \int_0^1 \left(\nabla^2 f(x^* + t(x^u - x^*)) - \nabla^2 f(x^u) \right) (x^u - x^*) dt \right\|$$

$$\leq \mu \int_0^1 \left\| \left(\nabla^2 f(x^* + t(x^u - x^*)) - \nabla^2 f(x^u) \right) (x^u - x^*) \right\| dt$$

(FACIO UNIFORME)

$$\leq \mu \int_0^1 \left\| \nabla^2 f(x^* + t(x^u - x^*)) - \nabla^2 f(x^u) \right\| - \|x^u - x^*\| dt \quad \text{1}$$

$$\Rightarrow \underline{x^k \in B_\varepsilon(x^*) \text{ per Hp}}, \underline{x^* \in B_\varepsilon(x^*)}, x^* + t(x^k - x^*) =$$

$$= t x^* + (1-t) x^*$$

(DEFINIZIONE DI CONVESSITÀ)

$$\Rightarrow \underline{\text{per la convessità di } B_\varepsilon(x^*)} \Rightarrow \boxed{x^* + t(x^k - x^*) \in B_\varepsilon(x^*)}$$

possiamo anche dire che:

$$\Delta \leq \mu \int_0^1 \|x^k - x^*\| dt$$

$$= \sigma \int_0^1 \|x^k - x^*\| dt = \sigma \|x^k - x^*\| \text{ con } \sigma \in (0, 1) \\ \leq \|x^k - x^*\|$$

$$\leq \varepsilon$$

$$\Rightarrow \underline{x^{k+1} \in B_\varepsilon(x^*)} \Rightarrow \{x^k\} \subseteq B_\varepsilon(x^*) \checkmark$$

$$\text{mentre } \|x^{k+1} - x^*\| \leq \sigma \|x^k - x^*\|$$

$$\leq \sigma^2 \|x^{k-1} - x^*\|$$

$$\leq \sigma^3 \|x^{k-2} - x^*\|$$

i

$$\Rightarrow \|x^{n+1} - x^*\| \leq \sigma^n \|x^0 - x^*\|$$

entonces $0 \leq \lim_{k \rightarrow \infty} \|x^{k+1} - x^*\| \leq \lim_{k \rightarrow \infty} \sigma^k \|x^0 - x^*\| = 0$ por que $\sigma < 1$

$$\Rightarrow \lim_{k \rightarrow \infty} \|x^k - x^*\| = 0 \Rightarrow x^k \rightarrow x^*$$

Dim ③

desarrollando con:

$$0 \leq \|x^{n+1} - x^*\| \leq \mu \int_0^1 \|\nabla^2 f(x^* + t(x^n - x^*)) - \nabla^2 f(x^n)\| \|x^n - x^*\| dt$$

dividiendo por $\|x^n - x^*\|$:

$$0 \leq \frac{\|x^{n+1} - x^*\|}{\|x^n - x^*\|} \leq \mu \int_0^1 \|\nabla^2 f(x^* + t(x^n - x^*)) - \nabla^2 f(x^n)\| dt$$

E igualando con $x^k \rightarrow x^*$ se ve que:

$$0 \leq \lim_{k \rightarrow \infty} \frac{\|x^{k+1} - x^*\|}{\|x^k - x^*\|} \leq \mu \int_0^1 \|\nabla^2 f(x^*) - \nabla^2 f(x)\| dt = 0$$

$\Rightarrow \underline{x}^n$ converges in most supernorms \square

$$\|\nabla^2 f(x) - \nabla^2 f(y)\| \leq L \|x-y\|$$

INSURE, SE $\nabla^2 f(x)$ IS LIPSCHITZ-CONTINUOUS, ALSO:

$$\|x^{n+1} - x^*\| \leq \mu \int_0^1 \|\nabla^2 f(x^* + t(x^n - x^*)) - \nabla^2 f(x^n)\| \cdot \|(x^n - x^*)\| dt$$

$$\leq \mu \int_0^1 L \|(x^* + t(x^n - x^*) - x^n)\| \cdot \|(x^n - x^*)\| dt$$

$$= L \mu \int_0^1 \|(x^n - x^*)\|^2 (1-t) dt$$

$$= L \mu \int_0^1 \|(x^n - x^*)\|^2 (1-t) dt$$

$$= \frac{1}{2} L \mu \frac{\|(x^n - x^*)\|^2}{\|(x^n - x^*)\|^2}$$

PROVE: $\frac{\|x^{n+1} - x^*\|}{\|(x^n - x^*)\|^2} \leq \frac{\mu L}{2} \Rightarrow \lim_{k \rightarrow \infty} \frac{\|x^{n+1} - x^*\|}{\|(x^n - x^*)\|^2} \leq \frac{\mu L}{2}$

SOLEN x^n CONVERGE IN MOST PRODUCTS! \square

METODO

 f CONVEXA f FORTAMENTE CONVEXA

	TASSO	COMPLICATITÀ	TASSO	COMPLICATITÀ
GRADIENTE	SUBLINEARE	$O(\frac{1}{\epsilon})$	LINARE	$O(\log \frac{1}{\epsilon})$
NESTEROV	SUBLINEARE	$O(\frac{1}{\sqrt{\epsilon}})$	LINARE	$O(\log \frac{1}{\epsilon})$
NEWTON	SUPERLINEARE	$O(\frac{1}{\sqrt{\epsilon}})$	SUBLINEARE	$O(\log \log \frac{1}{\epsilon})$

OSSERVAZIONI

- NEL CASO DI f CONVEXA IL TASSO È SUBLINEARE E NON SUPERLINEARE POICHÉ SI RICHIODE $\nabla^2 f$ NON SEMPRE, OSSIA DEFINITA-POSITIVA. SI AMMIRAGLIO NEL CASO DI f FORTAMENTE CONVEXA. QUINDI LA CONVESSITÀ GARantisce solo che $\nabla^2 f$ sia SEMI-DEFINITA POSITIVA.
- SE SI CONSIDERA SOLO IL TASSO IL METODO DI NEWTON È DOMINANTE MA SE SI CONSIDERA TUTTO IL COSTO DI Ogni ITERAZIONE. INFATTI ESISTONO UNA ITERAZIONE PER IL METODO DEL GRADIENTE COSTA $O(n)$, NEL CASO DEL METODO DI NEWTON IL COSTO È MOLTO MILLORI \rightarrow TRADE-OFF TRA VELOCITÀ DI COMPUTAZIONE E VELOCITÀ DI ESECUZIONE.

VEDIAMO I PROBLEMI CHE POSSANO PRESENTARSI CON METODO DI NEWTON

1) SE $\nabla^2 f(x^n)$ NON È INVERIBILE ALLORA NON È POSSIBILE ESEGUIRE UN ALGORITMO CON NEWTON. SI ESEGUE PUNTI CON PASSO DEL METODO DEL GRADIENTE

2) SE $\nabla^2 f(x^n)$ NON È DEFINITA POSITIVA ALLORA $d_n = -[\nabla^2 f(x^n)]^{-1} \nabla f(x^n)$ NON È UNA DIREZIONE DI DISCESA \rightarrow PASSO DEL GRADIENTE

3) SE $f(x^{n+1}) \geq f(x^n)$, OVRDO $\lambda_n = 1$ NON È BONS, ALLORA SI VIENE ESEGUITE UNA LINEARIZZAZIONE

METODO DI NEWTON OROBAMENTE CONVERGENTE

UN ALGORITMO ITERATIVO SI DICE OROBAMENTE CONVERGENTE SE PRODUCE SEQUENZE $\{x^n\}$ CON LE SEGUENTI PROPRIETÀ:

- $\{x^n\}$ HA PUNTI DI ACCUMULAZIONE ED ORARIO DI QUESTI È UN PUNTO STABILISSIMO
- NESSUNO DEI PUNTI DI ACCUMULAZIONE È UN MASSIMO LOCALE

SE $\{x^n\}$ CONVERGE AD UN MINIMO LOCALE x^* ALLORA ESISTE UN

Passo \bar{H} FASE CUE:

$$\forall k \geq \bar{H} \text{ si ha } x^{k+1} = x^k - [\nabla^2 f(x^k)]^{-1} \nabla f(x^k)$$

L'

Dopo questo passo \bar{H} in poi, il passo
è sempre quello del metodo di Newton

METODO PASSO NEWTON

CONSIDERAMO IL CASO PLESSIVO $\min_x \frac{1}{2} x^T P x - c^T x$ con $\nabla f(x) = P x - c$
 $\nabla^2 f(x) = P$

se calcoliamo $\nabla f(x) - \nabla f(y)$ otteniamo:

$$\nabla f(x) - \nabla f(y) = P x - c - P y + c = P(x - y) = \nabla^2 f(x)(x - y)$$

E, all'interno di un iterazione iterativa si ha:

$$\nabla^2 f(x^{k+1}) - \nabla^2 f(x^k) = P(x^{k+1} - x^k)$$

PER IL ALGORITMO ITERATIVO VISTI:

METODO DEL GRADIENTE: $x^{n+1} = x^n - \alpha_n \nabla f(x^n)$

METODO DI NEWTON: $x^{n+1} = x^n - \frac{\alpha_n}{\|J\|} [\nabla^2 f(x^n)]^{-1} \nabla f(x^n)$

In questo caso si ha: $x^{n+1} = x^n - \alpha_n \underbrace{B_n}_{J_p} \nabla f(x^n)$

C'è idea e quindi questa di usare $x^{n+1} = x^n - \alpha_n B_n^{-1} \nabla f(x^n)$

con $B_n \approx \nabla^2 f(x^n)$ che soddisfa l'equazione newton.

Si distinguono due tipi di formule di aggiornamento:

AGGIORNAMENTO DIRETTO: $x^{n+1} = x^n - \alpha_n B_n^{-1} \nabla f(x^n)$ con $B_n \approx \nabla^2 f(x^n)$

AGGIORNAMENTO INVERSO: $x^{n+1} = x^n - \alpha_n H_n \nabla f(x^n)$ con $H_n \approx [\nabla^2 f(x^n)]^{-1}$

permettendo

scriviamo che $B_{n+1} = B_n + 4B_n$ e $H_{n+1} = H_n + 4H_n$

Sono poi $S_n = x^n - x^{n+1}$ e $\gamma_n = \nabla f(x^n) - \nabla f(x^{n+1})$, allora:

equazione newton

$$B_n S_n = \gamma_n$$

$$\Rightarrow B_{n+1} S_{n+1} = \gamma_{n+1}$$

$$S_n = H_n \gamma_n$$

$$\Rightarrow H_{n+1} \gamma_{n+1} = S_{n+1}$$

ALGORITMO GENERO

DATI: $x^0 \in \mathbb{R}^n$, $\mathcal{U} = \mathbb{C}$, $B_0 \in \mathbb{R}^{n \times n}$ simmetrico E D.P

WHILE $(\nabla f(x^k) \neq 0)$

- $d_k = -B_k^{-1} \nabla f(x^k)$

- calcolo α_k

- $x^{k+1} = x^k + \alpha_k d_k$

$$B_{k+1} s_{k+1} = r_{k+1}$$

- calcolo B_{k+1} t.c.

$$B_{k+1}(x^{k+1} - x^k) = \nabla f(x^{k+1}) - \nabla f(x^k)$$

- $k = k+1$

DOVE SODDISFARE
l'equazione quasi-newton

END

AGGIORNAMENTO DI RANGO 1

- VERSIONE DIRETTA:

$$B_{k+1} = B_k + \rho_k \mu_k v_k v_k^T$$

$$\rho_k \in \mathbb{R}, \mu_k, v_k \in \mathbb{R}^n$$

- VERSIONE INVERSA:

$$H_{k+1} = H_k + \rho_k \mu_k v_k v_k^T$$

AGGIORNAMENTO DI RANGO 2

VERSIONE DIRETTA:

$$\boxed{B_{n+1} = B_n + \alpha_n \mu_n \mu_n^T + b_n v_n v_n^T}$$

$\alpha_n, b_n \in \mathbb{R}, \mu_n, v_n \in \mathbb{R}^n$

VERSIONE INVERSA:

$$\boxed{H_{n+1} = H_n + \alpha_n \mu_n \mu_n^T + b_n v_n v_n^T}$$

FORMULE BFGS

VERSIONE DIRETTA:

$$B_{n+1} = B_n + \frac{Y_n Y_n^T}{Y_n^T S_n} - \frac{B_n S_n S_n^T B_n^T}{S_n^T B_n S_n}$$

VERSIONE INVERSA:

$$H_{n+1} = H_n + \left(I + \frac{Y_n^T H_n Y_n}{S_n^T Y_n} \right) \frac{S_n S_n^T}{S_n^T Y_n} - \frac{S_n Y_n^T H_n + H_n Y_n S_n^T}{S_n^T Y_n}$$

MOSTRAMO CHE LA VERSIONE DIRETTA SODDISFA L'EQUAZIONE QUASI-NEWTON:

$$\boxed{B_{n+1} S_n = B_n S_n + \frac{Y_n Y_n^T S_n}{Y_n^T S_n} - \frac{B_n S_n B_n^T S_n}{S_n^T B_n S_n} = B_n S_n + Y_n - B_n S_n = Y_n}$$

✓

ANALOGAMENTE VALG ANCHE PER LA FORMULA INVERSA.

SE CONSIDERAMO $d_n = -B_n^{-1} \nabla f(x^n)$ OPPURE $d_n = -H_n^{-1} \nabla f(x^n)$ SI HA CHE $d_n \in$

DIREZIONE DI DISCESA SE LA MATRICE B_n OPPURE H_n SIAO DEFINITA POSITIVA

PROPOSIZIONE:

SE B_n DEFINITA POSITIVA. SE VALG $Y_n^T S_n > 0$ ALLORA B_{n+1} , OTTOPOI OTTENUTO UN

AGGIORNAMENTO BFGS, E ALLORA CHE MATEICE DEFINITA POSITIVA.

NOTARE SE \mathbf{B}_0 E' DEFINITA POSITIVA E VALE $S_H^T y_H > 0$ AD OGNI ITERAZIONE, ALLORA

TUTTA LA SEQUENZA $\{\mathbf{B}_H\}$ E' DEFINITA POSITIVA

MA COME E' POSSIBILE GARANTIRE CHE $S_H^T y_H > 0$?

$$S_H = x^{H+1} - x^H = x^H + \alpha_H d_H - x^H = \alpha_H d_H$$

SUPPONIAMO CHE $\alpha_H d_H^T y_H > 0 \Rightarrow \alpha_H d_H^T (\nabla f(x^{H+1}) - \nabla f(x^H)) > 0$

$$\alpha_H > 0 \Rightarrow d_H^T (\nabla f(x^{H+1}) - \nabla f(x^H)) > 0$$

$$\Rightarrow d_H^T \nabla f(x^{H+1}) > d_H^T \nabla f(x^H)$$

PER LA CONDIZIONE DI WEIE SI HA

$$\nabla f(x^H + \alpha_H d_H)^T d_H \geq \sigma \nabla f(x^H)^T d_H$$

TALE CONDIZIONE CI GARantisce CHE:

$$\nabla f(x^H + \alpha_H d_H)^T d_H \geq \nabla f(x^H)^T d_H$$

PROGETTO DI CONVERGENZA

. SE f E' CONVessa ALLORA SI HA CONVERGENZA GLOBALE

. SE f E' FORTEMENTE CONVessa ALLORA SI HA UN TASSO DI CONVERGENZA SUPERLINEARE

PROBLEMI SU LARGA SCALA $\rightarrow \min_{x \in \mathbb{R}^n} f(x)$ con $n \approx 10^6$

IN QUESTO TIPO DI PROBLEMI L'INGORGIAMENTO BFGS PRESENTA DUE PROBLEMI:

- MEMORIZZAZIONE DI H_n POICHE' E' UNA MATRICE DENSAMENTE POPOLATA
- CALCULO DI $d_n = -H_n \nabla f(x^n)$

SI RISOLVE UTILIZZANDO DUE STRATEGIE:

1)

SORVETE H_{n+1} IN MODO RIPETITIVO

$$H_{n+1} = V_n^T [H_n V_n + \rho_n S_n S_n^T] \quad \text{con} \quad \rho_n = \frac{1}{\gamma_n^T S_n} \quad \text{e} \quad V_n = I - \rho_n \gamma_n \gamma_n^T$$

$$= V_n^T \left(V_{n-1}^T H_{n-1} V_{n-1} + \frac{1}{\gamma_{n-1}^T S_{n-1}} S_{n-1} S_{n-1}^T \right) V_n + \frac{1}{\gamma_n^T S_n} S_n^T S_n \dots$$

⋮

$$= P(H_0, \gamma_0, S_0, \gamma_1, S_1, \dots, \gamma_n, S_n)$$

QUESTO SIGNIFICA CHE H_{n+1} È UNA FUNZIONE (P) DI H_0 E DELLA SEQUENZA $\{\gamma_i\}$ E $\{S_i\}$

SE PONGO $H_0 = \mathbf{J}^T$ POSSO RESTRNUIRE H_{H+1} PARANDO DA UNO SCORSO E 2^{es} VETTORI IN \mathbb{R}^m !

2)

TRONCARÈ IL PROCESSO RICORSIVO

FERMANDO LA RICORSIONE OTTERREMO QUINDI:

$$H_{H+1} = H(H_0, y_0, s_0, \dots, y_H, s_H) = H(\underbrace{H_{H-m}, y_{H-m}, s_{H-m}, \dots, y_H, s_H}_Z, H_0 = \mathbf{J}^T)$$

QUESTO CI PERMETTE, AD OGNI ITERAZIONE, DI AVERE IN MEMORIA SOLO UNO SCORSO DI m VALORI INVECE CHE m^2 VALORI.

SPERIMENTALMENTE SI OSSERVA ANCHE CHE CON $m \approx 10$ SI PUÒ CONSEGUIRE AD OBTENERE UN'OTTIMA APPROSSIMAZIONE DELLA MATEMATICA MESSA.

ESISTE UN ALGORITMO (**METODO HG**) CHE CONSENTE, GRAVITÀ \mathbf{y}_{mm} PRODOTTI, DI SVOLGERE IN MODO "IMPUCRO" IL PRODOTTO $H_H D_f C^H$ USANDO SOLO I VALORI DI $\mathbf{y}, s_{H-m}, y_{H-m}, \dots, s_K, y_K$

LIMITED
MEMORY

UN'ALTRA VARIANTE DI BFGS CHE USA QUESTO METODO È DETTA **L-BFGS** CHÉ È UN ALGORITMO DI OTTIMIZZAZIONE NON LINEARE E NON VINCOLATA PIÙ PERFORMANCE ANCHE SE NON HA CONVERGENZA GARANTITA!